





# cv and ml

Владимир Глазачев  
cv в [rosebud.ai](https://rosebud.ai)

































Ну и так далее



# Vector



# Raster



AI

EPS

CGM

PDF

SVG

CDR

BMP

TIFF


PCX

GIF

PNG



JPEG

## Vector



1 circle of color red with radius  $r_1$  at position  $(x_1, y_1, z_1)$   
2 circle of color blue with radius  $r_2$  at position  $(x_2, y_2, z_2)$   
3

## Raster



# Что у нас?

Будет:

- Растровые картинки - тензор размера  $height \times width \times num\_channels$
- Data Driven - картинки к нам откуда то пришли в разумном количестве
- Хотим делать какой то ml вокруг этого

Не будет:


- traditional cv, восприятие, цветовые пространства, как работают камеры, как хранить картинки, исторические справки, физика света и цвета и т.д.
  - про это интересно можно послушать тут - <https://www.youtube.com/watch?v=zNCvTcoM1I4>



## Dataset



Input




Output

ML algo

Classes:

dog or food or  
nothing?


Dataset



Что нам нужно?

- Данные - куча картинок

Dataset




Что нам нужно?

- Данные - куча картинок
- Алгоритм - мл моделька




Dataset



Что нам нужно?

- Данные - куча картинок
- Алгоритм - мл моделька
- Фичи - ???

Dataset



Что нам нужно?

- Данные - куча картинок
- Алгоритм - мл моделька
- Фичи - ???

# Крафтим фичи руками

- Используем пиксели as is
- Можно если все картинки одинакового размера
- Если ML модель не использует доп связи - то пиксели не связаны



image 64x64x3



1d tensor (12288,)




# Крафтим фичи руками

- Считаем гистограммы по цветам
- Работает с variable размерами



image 64x64x3







1d tensor (255\*3,)

# Крафтим фичи руками - локальные

- Histogram of Oriented Gradients (HOG)
- Scale-Invariant Feature Transform (SIFT)
- Speeded Up Robust Feature (SURF)
- ... и так далее



image 64x64x3



# Крафтим фичи руками - bow


Из пикселей или локальных фич можем взять точки интереса, нарезать картинку оттуда и использовать их в мешке слов



image 64x64x3

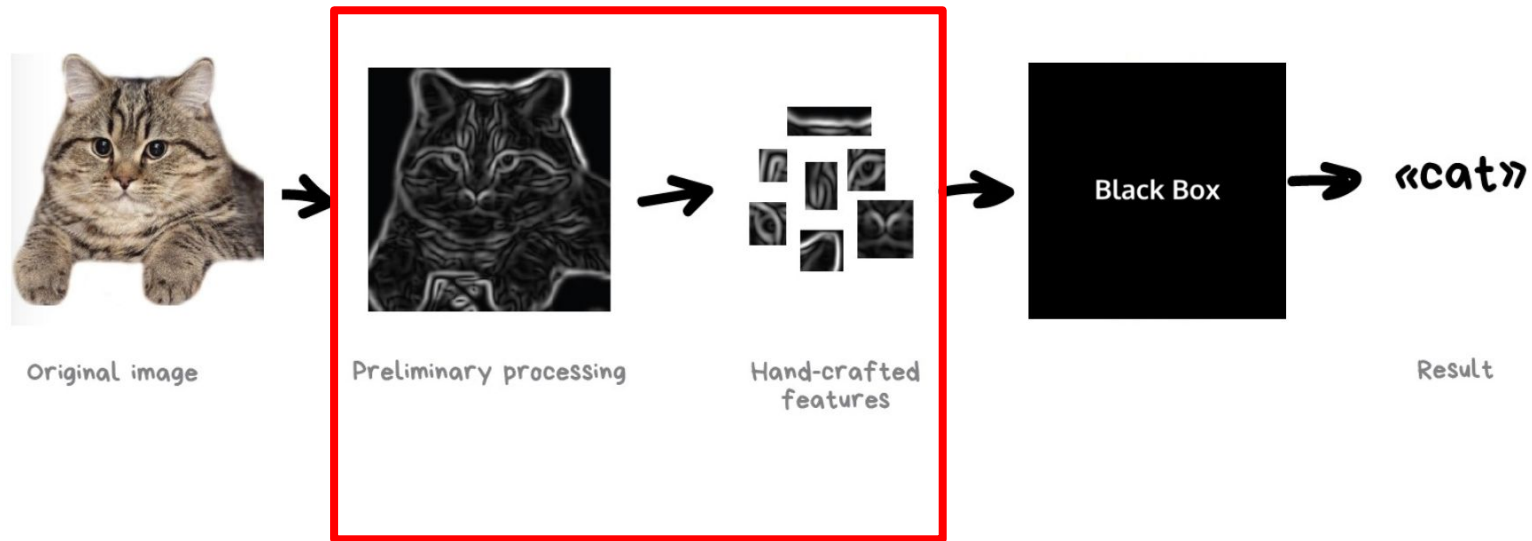


# Итого



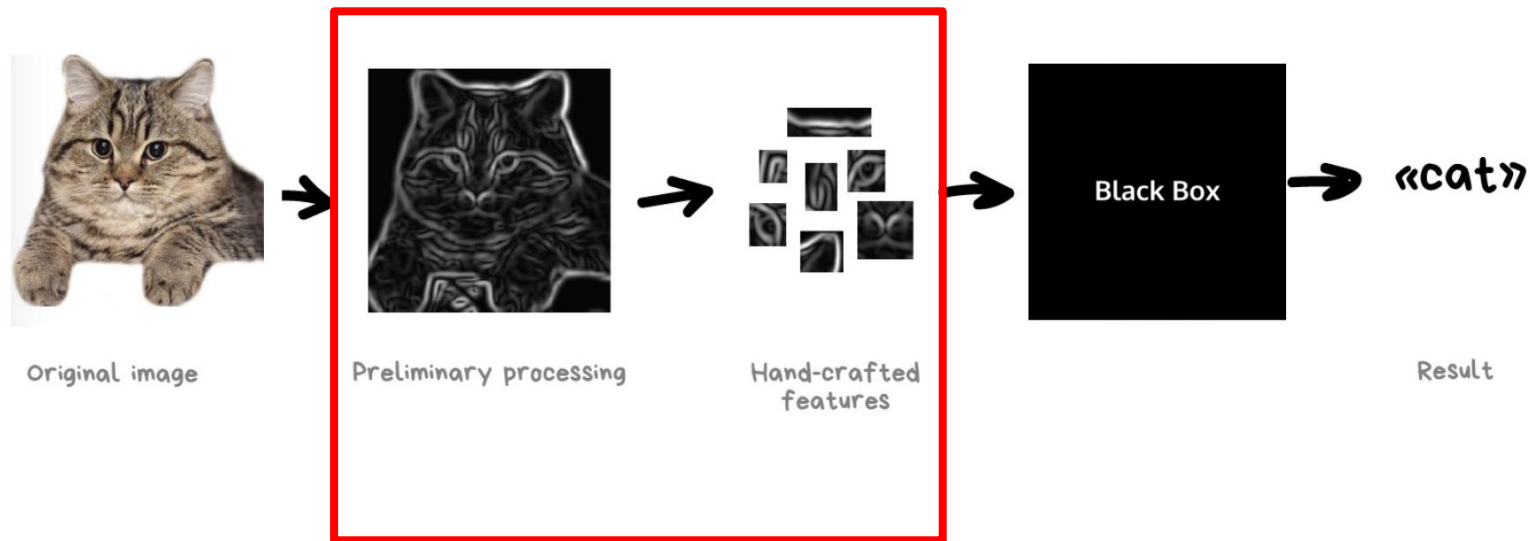


# Итого



Хотим избавиться от ручных фич


# Итого



Хотим избавиться от ручных фич


У нас было это свойство в пиксель фичах, но не учитывались связи между пикселями ; через локальные можно добавить - но все еще делаем это руками

# Deep Learning quick intro - linear



$$y = Wx$$


# Deep Learning quick intro - linear



$$y = W_2 (W_1 x)$$

чего то не хватает

# Deep Learning quick intro - linear



нелинейность -  $\text{relu} = \max(0, x)$ ,  $\text{sigmoid} = 1/(1 + e^{(-x)})$  и т д


$$y = W_2 \text{relu}(W_1 x)$$



# Deep Learning quick intro


$y = W_2 \text{ nonlinearity}(W_1 x)$  - двухслойная нейронная сеть

- комбинация линейных слоев и нелинейностей - универсальный аппроксиматор
- представляется как вычислительный граф



# Deep Learning quick intro - оптимизируем

- для линейных моделей у нас были аналитические решения
- сейчас у нас произвольный граф, в общем случае нейронная сеть - невыпуклая функция
- оптимизируем градиентным спуском, над уметь считать градиенты
- оптимизируем какую нибудь loss функцию, для классификации - кроссентропию например



# Deep Learning quick intro - оптимизируем

Backpropagation:  
Simple Example

$$f(x, y, z) = (x + y)z$$


e.g.  $x = -2, y = 5, z = -4$

1. **Forward pass:** Compute outputs

$$q = x + y \quad f = qz$$

2. **Backward pass:** Compute derivatives

Want:  $\frac{\partial f}{\partial x}, \frac{\partial f}{\partial y}, \frac{\partial f}{\partial z}$



# Deep Learning quick intro - оптимизируем

Backpropagation:  
Simple Example

$$f(x, y, z) = (x + y)z$$


e.g.  $x = -2, y = 5, z = -4$

1. **Forward pass:** Compute outputs

$$q = x + y \quad f = qz$$

2. **Backward pass:** Compute derivatives

Want:  $\frac{\partial f}{\partial x}, \frac{\partial f}{\partial y}, \frac{\partial f}{\partial z}$

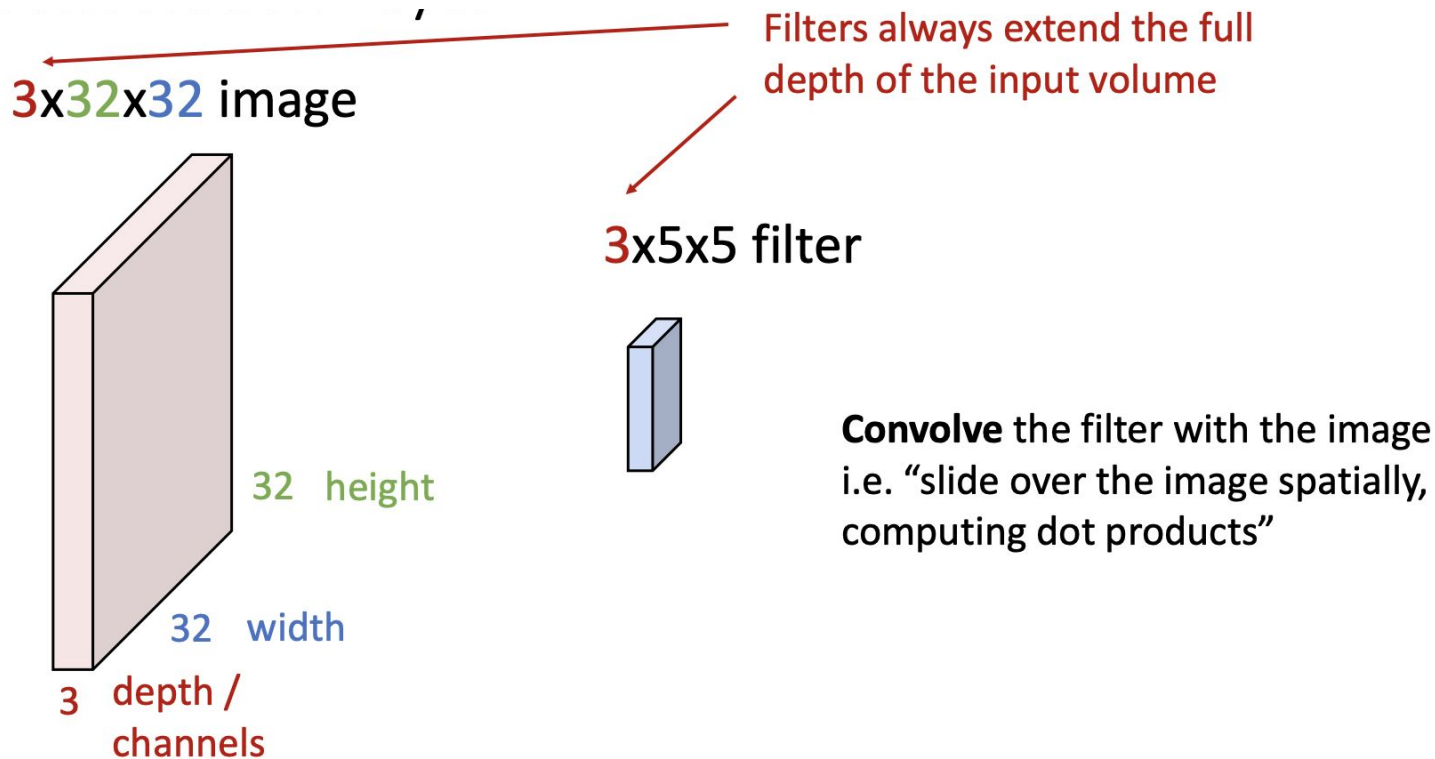


**Chain Rule**

$$\frac{\partial f}{\partial x} = \frac{\partial q}{\partial x} \frac{\partial f}{\partial q}$$

$$\frac{\partial q}{\partial x} = 1$$


# Deep Learning - conv networks





# Deep Learning - conv networks

3x32x32 image




**1 number:**

the result of taking a dot product between the filter and a small 3x5x5 chunk of the image  
(i.e.  $3 \times 5 \times 5 = 75$ -dimensional dot product + bias)


$$w^T x + b$$

# Deep Learning - conv networks




# Deep Learning - conv networks

3x32x32 image




Also 6-dim bias vector:




Convolution  
Layer

6x3x5x5  
filters



28x28 grid, at each  
point a 6-dim vector



Stack activations to get a  
6x28x28 output image!

# Deep Learning - conv networks

A closer look at spatial dimensions

0	0	0	0	0	0	0	0	0
0								0
0								0
0								0
0								0
0								0
0								0
0								0
0	0	0	0	0	0	0	0	0

Input: 7x7

Filter: 3x3

Output: 5x5

In general:

Input:  $W$

Filter:  $K$

Padding:  $P$


Output:  $W - K + 1 + 2P$

Very common:

Set  $P = (K - 1) / 2$  to  
make output have  
same size as input!

# Deep Learning - conv networks

Стакая конволюции друг за другом мы не уменьшаем размерность



## Hyperparameters:

Kernel Size



Stride

Pooling function



# Deep Learning - conv networks

## Max Pooling



Max pooling with 2x2  
kernel size and stride 2


6	8
3	4

Introduces **invariance** to  
small spatial shifts  
No learnable parameters!

# Deep Learning - conv networks

Classic architecture: [Conv, ReLU, Pool] x N, flatten, [FC, ReLU] x N, FC


## Example: LeNet-5



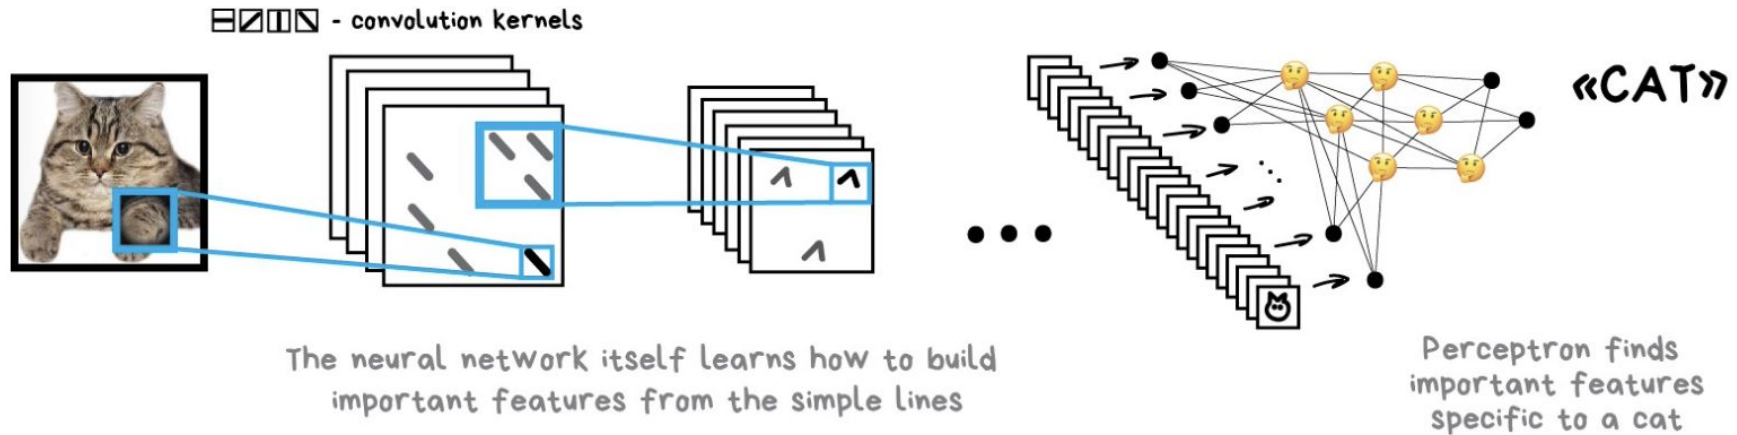
# Deep Learning - conv networks

## Example: LeNet-5

Layer	Output Size	Weight Size
Input	1 x 28 x 28	
Conv ( $C_{out}=20$ , $K=5$ , $P=2$ , $S=1$ )	20 x 28 x 28	20 x 1 x 5 x 5
ReLU	20 x 28 x 28	
MaxPool( $K=2$ , $S=2$ )	20 x 14 x 14	
Conv ( $C_{out}=50$ , $K=5$ , $P=2$ , $S=1$ )	50 x 14 x 14	50 x 20 x 5 x 5
ReLU	50 x 14 x 14	
MaxPool( $K=2$ , $S=2$ )	50 x 7 x 7	
Flatten	2450	
Linear (2450 -> 500)	500	2450 x 500
ReLU	500	
Linear (500 -> 10)	10	500 x 10



# Что получилось?



deep learning во многом про feature (representation) learning ; мы не хотим крафтить фичи руками а хотим просто засыпать модель данными

# Что дальше?

- Глубже смотрим в CNN
- Задачи зрения - детекция, сегментация, мультимодальные задачи
- Современные архитектуры
- Генерация изображений
- Как это все запускать и использовать

# Ссылки

- куча изображений и отсылок из [https://vas3k.com/blog/machine\\_learning/](https://vas3k.com/blog/machine_learning/)
- примеры и картинки из курса csc по compvision  
<https://www.youtube.com/watch?v=zNCvTcoM1I4>
- примеры и картинки из курса по compvision michigan university  
<https://www.youtube.com/watch?v=ANyxBVxmdZ0>
- если есть вопросы можно мне написать в телеграмме @vladgl
-